

CASE TÉCNICO

Modelo Preditivo de Inadimplência

Datarisk — Cientista de Dados Júnior

Sumário

1. Contexto e Objetivo
2. Dados Disponíveis
3. Análise Exploratória (EDA)
4. Construção do Target
5. Feature Engineering
6. Estratégias contra Overfitting e Viés
7. Modelagem
8. Avaliação do Modelo
9. Inteligência de Negócio
10. Conclusão

1. Contexto e Objetivo

A Datarisk é uma consultoria especializada em inteligência de crédito que atua com grandes instituições financeiras. Neste projeto, o desafio é prever, com antecedência, quais clientes têm maior probabilidade de não pagar uma cobrança mensal no prazo esperado.

Definição de Inadimplência

Um pagamento é considerado INADIMPLENTE se for realizado com 5 ou mais dias de atraso em relação à data de vencimento.

Objetivo

- Desenvolver um modelo preditivo de probabilidade de inadimplência
- Gerar previsões para 12.275 cobranças da base de teste (jul-nov/2021)
- Entregar o arquivo `submissao_case.csv` com as probabilidades previstas
- Extrair inteligência de negócio acionável a partir dos resultados

2. Dados Disponíveis

Quatro bases de dados foram fornecidas, relacionadas por ID_CLIENTE e SAFRA_REF:

Base	Descrição	Linhas	Chave
base_cadastral.csv	Perfil cadastral dos clientes	1.315	ID_CLIENTE
base_info.csv	Renda e funcionários por mês	24.401	ID_CLIENTE + SAFRA_REF
base_pagamentos_desenvolvimento.csv	Histórico de cobranças com pagamentos	77.414	ID_CLIENTE + SAFRA_REF
base_pagamentos_teste.csv	Cobranças recentes sem pagamento	12.275	ID_CLIENTE + SAFRA_REF

3. Análise Exploratória (EDA)

Target

- Taxa global de inadimplência: 7% — dataset desbalanceado
- Distribuição do atraso fortemente concentrada em zero — maioria paga no dia
- Pico expressivo em fev-mar/2020 (14-16%) coincidindo com início da pandemia de COVID-19
- Base de teste cobre jul-nov/2021 — cenário pós-pandemia, mais estável

Valor e Taxa

- Relação inversa entre valor e inadimplência: cobranças menores (Q1) têm taxa de 15%, quase 4x maior que os demais quartis (~4-5%)
- Hipótese: clientes priorizam pagamentos grandes para evitar juros acumulados
- Taxa de juros tem sinal fraco mas coerente: taxas maiores associadas a inadimplência levemente maior

Perfil do Cliente

Variável	Grupo	Taxa de Inadimplência
Porte	PEQUENO	~9%
Porte	MEDIO	~6.5%
Porte	GRANDE	~5.5%
Segmento	Serviços	~8.5%
Segmento	Indústria	~7.5%
Segmento	Comércio	~4.5%
Tipo	Pessoa Física (PF)	~20%
Tipo	Pessoa Jurídica (PJ)	~7%

Comportamento Histórico Individual

- 70% dos clientes nunca inadimpliram — histórico individual é o sinal mais forte
- Apenas 30% tiveram ao menos 1 atraso
- Clientes com poucas cobranças têm taxas individuais voláteis — features históricas precisam considerar volume

4. Construção do Target

A variável target foi construída a partir da diferença entre DATA_PAGAMENTO e DATA_VENCIMENTO:

INADIMPLENTE = 1 se (DATA_PAGAMENTO - DATA_VENCIMENTO) >= 5 dias

Classe	Registros	% do Total
Adimplente (0)	71.975	92.98%
Inadimplente (1)	5.439	7.02%

5. Feature Engineering

29 features foram criadas em 5 grupos. A regra central: nenhuma feature pode usar informações da safra atual ou futuras (anti-leakage).

Cobrança Atual

Feature	Descrição
prazo_dias_adj	Dias entre emissão e vencimento (clipado 0-200)
mes_vencimento	Mês do vencimento — captura sazonalidade
dia_vencimento	Dia do vencimento — padrões intra-mensais
log_valor	Log do valor a pagar — reduz efeito de outliers
safra_int	Safra como inteiro — captura tendência temporal
TAXA	Taxa de juros da cobrança

Flags de Anomalia

Feature	Descrição	Taxa Inadimplência
flag_prazo_negativo	Vencimento anterior à emissão	96.3% vs 7.0%
flag_prazo_longo	Prazo acima de 200 dias	43.9% vs 7.0%
flag_valor_nulo	VALOR_A_PAGAR ausente	9.4% vs 7.0%

Histórico do Cliente

Todas calculadas com shift(1) — apenas safras anteriores à atual.

Feature	Descrição
hist_tx_inad	Taxa de inadimplência histórica acumulada
hist_n_inad	Número absoluto de inadimplências
hist_n_safras	Quantidade de safras com histórico
hist_inad_ult3m	Taxa de inadimplência nos últimos 3 meses
hist_inad_ult6m	Taxa de inadimplência nos últimos 6 meses
hist_atraso_medio	Atraso médio histórico em dias
hist_atraso_max	Maior atraso já registrado
hist_meses_desde_inad	Meses desde a última inadimplência (NaN = nunca atrasou)

Cadastral e Info Mensal

Feature	Descrição
PORTE	Tamanho da empresa
SEGMENTO_INDUSTRIAL	Setor de atuação
DDD / CEP_2_DIG	Proxies de região geográfica
is_pf	Flag binária: 1 = Pessoa Física
tempo_relacionamento	Dias desde o cadastro até a safra
log_renda	Log da renda/faturamento do mês anterior
log_func	Log do número de funcionários
ratio_valor_renda	Valor da cobrança / renda — esforço financeiro

6. Estratégias contra Overfitting e Viés

Risco	Estratégia Adotada
Data Leakage	Features históricas com shift(1) — apenas safras anteriores
Target Leakage	Nenhuma feature derivada de DATA_PAGAMENTO ou atraso_dias
Overfitting	Validação Out-of-Time — nunca split aleatório em séries temporais
Viés Temporal	COVID (fev-mar/2020) isolado no treino, avaliação em safras recentes
Desbalanceamento	Métricas AUC-ROC e KS — nunca acurácia. is_unbalance=True no LightGBM

7. Modelagem

Algoritmo — LightGBM

- Padrão da indústria para scoring de crédito
- Lida nativamente com NaN e variáveis categóricas
- Robusto a dados desbalanceados via `is_unbalance=True`
- Interpretável via feature importance

Split Out-of-Time

Conjunto	Safras	Registros	Taxa Inadimplência
Treino	2018-08 → 2021-03	70.012	7.10%
Validação OOT	2021-04 → 2021-06	7.402	6.24%
Teste	2021-07 → 2021-11	12.275	—

Parâmetros Principais

Parâmetro	Valor	Justificativa
<code>learning_rate</code>	0.05	Aprendizado lento e estável
<code>num_leaves</code>	63	Controla complexidade da árvore
<code>min_child_samples</code>	30	Evita overfitting em folhas pequenas
<code>feature_fraction</code>	0.8	Regularização por subsample de features
<code>is_unbalance</code>	True	Trata desbalanceamento de 7%
<code>early_stopping</code>	50 rounds	Parou na iteração 131 de 1000

8. Avaliação do Modelo

Métricas

Métrica	Valor	Referência do Mercado
AUC-ROC (treino)	0.9895	—
AUC-ROC (validação OOT)	0.9542	Modelos em produção: 0.70-0.85
Average Precision	0.6670	Penaliza falsos positivos
KS Statistic	0.7877	KS > 0.40 já é bom em crédito

Calibração por Decil

Decil	Registros	Inadimplentes	Taxa Real
1 a 7 (menor risco)	5.181	17	~0%
8	740	16	2%
9	740	72	10%
10 (maior risco)	741	357	48%

Curva de Ganho

Abordando 10% da base → captura 77.3% dos inadimplentes
Abordando 20% da base → captura 92.9% dos inadimplentes

Top 10 Features por Importância

Feature	Importância	Grupo
hist_inad_ult6m	14.0%	Histórico
CEP_2_DIG	12.3%	Cadastral
log_valor	11.6%	Cobrança
hist_inad_ult3m	10.2%	Histórico
hist_tx_inad	8.2%	Histórico
DDD	8.1%	Cadastral
prazo_dias_adj	6.3%	Cobrança
safra_int	4.3%	Temporal
hist_meses_desde_inad	3.3%	Histórico

Feature	Importância	Grupo
hist_atraso_medio	3.0%	Histórico

9. Inteligência de Negócio

9.1 Mapa de Risco — Segmento × Porte

Segmento \ Porte	PEQUENO	MEDIO	GRANDE
Comércio	9.88% □	8.61% □	8.34% □
Serviços	9.71% □	8.50% □	7.93% □
Indústria	6.53% □	7.35% □	9.56% □

- Comércio Pequeno e Serviços Pequeno — maior risco, combinação de porte reduzido com receita irregular
- Indústria Grande — resultado contraintuitivo, possivelmente por ciclos de pagamento mais longos
- Indústria Pequena — menor risco da carteira (6.53%)

9.2 Distribuição da Carteira por Faixa de Risco

Faixa	Cobranças	% da Base	Volume	% do Volume
Baixo (0-5%)	9.346	76.1%	R\$ 653M	81.6%
Médio (5-15%)	1.130	9.2%	R\$ 78M	9.7%
Alto (15-30%)	656	5.3%	R\$ 29M	3.6%
Crítico (>30%)	1.143	9.3%	R\$ 40M	5.0%

- 76% da base tem risco baixo e pode receber tratamento padrão sem ação proativa
- Os 9.3% críticos concentram R\$ 40M em volume de risco

9.3 Régua de Acionamento

Threshold	Clientes Acionados	% da Base	Volume Protegido
5%	2.929	23.9%	R\$ 147M
10%	2.132	17.4%	R\$ 91M
15%	1.799	14.7%	R\$ 69M
20%	1.594	13.0%	R\$ 59M
30%	1.143	9.3%	R\$ 40M
50%	757	6.2%	R\$ 23M

Recomendação: threshold de 15-20% como ponto de equilíbrio — aciona ~14% da base e protege R\$ 59-69M sem sobrecarregar a equipe de cobrança.

9.4 Evolução do Risco por Safra (jul-nov/2021)

Safra	Prob. Média	% Cobranças Críticas
2021-07	10%	10%
2021-08	10%	11%
2021-09	9%	10%
2021-10	9%	9%
2021-11	7%	7%

- Tendência positiva: risco médio caindo de 10% em jul/2021 para 7% em nov/2021
- Proporção de cobranças críticas também reduz consistentemente
- Indica melhora no perfil de pagamento da carteira ao longo do período

9.5 Perfil dos Clientes de Alto Risco (prob >= 30%)

- 1.143 cobranças em risco crítico | R\$ 40.3M em volume
- 98% são PJ — pessoas jurídicas dominam o risco crítico absoluto
- Serviços (41%) e Comércio (35%) concentram 76% das cobranças críticas
- Perfil típico: empresa de médio ou grande porte do setor de Serviços ou Comércio com histórico recente de atrasos

10. Conclusão

Abordando apenas 20% da base com maior probabilidade prevista, a equipe de cobrança captura 92.9% dos inadimplentes e protege aproximadamente R\$ 59M em volume financeiro — com uma fração do esforço que seria necessário sem o modelo.

Principais Resultados

- Modelo com AUC-ROC de 0.9542 e KS de 0.7877 na validação Out-of-Time
- 29 features construídas em 5 grupos — sem data leakage
- Validação temporal rigorosa — treino em 31 safras, validação nas 3 mais recentes
- Régua de acionamento pronta para uso operacional

Próximos Passos Recomendados

- Monitoramento mensal do KS e AUC — detectar drift do modelo
- Retreinamento a cada 6 meses com as safras mais recentes
- Investigar o comportamento atípico da Indústria Grande
- Avaliar criação de modelos segmentados por porte ou segmento industrial
- Definir threshold operacional em conjunto com a equipe de cobrança